ĐỀ CƯƠNG LUẬN VĂN THẠC SĨ

Họ tên học viên: Mai Trọng Nghĩa Giới tính: Nam
Ngày sinh: 05-10-1998 Nơi sinh: Sơn La
Điện thoại: 0969955743 Email: maitrongnghia98@gmail.com
Cơ quan công tác:
Cơ sở đào tạo: Trường Đại học Khoa Học Tự Nhiên, Đại học Quốc gia Hà Nội
Quyết định công nhận học viên số ……. ngày …… tháng …… năm 200….. của Hiệu trưởng trường Đại học Khoa Học Tự Nhiên.
Mã học viên: 24007795
Ngành: Toán-Cơ-Tin học
Chuyên ngành: Khoa Học Dữ Liệu Mã số: 62.48.01.03

Tên đề tài: Nghiên cứu phương pháp Federated Learning dựa trên Nested Learning

1. Cơ sở khoa học và thực tiễn của đề tài

1.1. Tính cấp thiết của đề tài nghiên cứu

Federated Learning (FL) đã trở thành một paradigm quan trọng trong machine learning phân tán, cho phép nhiều thiết bị cùng huấn luyện một mô hình toàn cục mà không cần chia sẻ dữ liệu một cách trực tiếp, từ đó có thể dễ dàng huấn luyện một mô hình trên một thiết bị nhưng vẫn duy trì được sự tổng quát toàn cục. Tuy nhiên, FL phải đối mặt với ba thách thức chính làm hạn chế hiệu quả và khả năng ứng dụng thực tế.

Thứ nhất, dữ liệu không đồng nhất (non-IID) là vấn đề nghiêm trọng nhất trong FL. Các client thường có dữ liệu với phân bố khác biệt đáng kể về đặc trưng, nhãn, hoặc số lượng mẫu. Zhao et al. (2018) đã chứng minh rằng dữ liệu non-IID có thể làm giảm độ chính xác của mô hình lên đến 55% so với trường hợp dữ liệu đồng nhất (IID). Nguyên nhân chính là hiện tượng "client drift", trong đó các bản cập nhật cục bộ từ các client khác nhau hướng về các hướng tối ưu không nhất quán, dẫn đến sự hội tụ chậm hoặc phân kỳ của mô hình toàn cục.

Thứ hai, catastrophic forgetting xảy ra khi mô hình quên kiến thức đã học trước đó trong quá trình cập nhật với dữ liệu mới. Trong môi trường FL, vấn đề này trở nên nghiêm trọng hơn do quá trình aggregation tại server có thể ghi đè kiến thức từ các client trước đó bằng các bản cập nhật từ client hiện tại. Điều này đặc biệt quan trọng trong các kịch bản continual learning, nơi dữ liệu và nhiệm vụ thay đổi liên tục theo thời gian.

Thứ ba, chi phí giao tiếp client-server cao là rào cản lớn cho việc triển khai FL trên quy mô lớn. Các phương pháp FL truyền thống như FedAvg thường yêu cầu hàng nghìn rounds truyền thông để đạt độ chính xác mong muốn, đặc biệt với dữ liệu non-IID. Điều này tiêu tốn băng thông mạng và năng lượng pin trên các thiết bị edge.

Các phương pháp hiện tại đã cố gắng giải quyết những thách thức này. FedProx thêm regularization để giữ mô hình cục bộ gần với mô hình toàn cục. SCAFFOLD sử dụng control variates để điều chỉnh client drift. Per-FedAvg áp dụng meta-learning cho personalization. Tuy nhiên, các phương pháp này đều có hạn chế chung là chỉ sử dụng single-level optimization, aggregation đơn giản tại server, và không có cơ chế hiệu quả để preserve kiến thức dài hạn.

Gần đây, Behrouz et al. (2025) đã giới thiệu Nested Learning (NL), một paradigm mới biểu diễn mô hình học máy như một hệ thống các bài toán tối ưu lồng nhau, mỗi bài toán có context flow, tần số cập nhật, và objective function riêng. NL đã chứng minh

hiệu quả vượt trội trong ba khía cạnh quan trọng. Về continual learning, Continuum Memory System (CMS) với multiple frequency levels cho thấy khả năng giảm catastrophic forgetting đáng kể trên các benchmark class-incremental như CLINC, Banking77, và DBpedia. Về in-context learning, Self-Referential Titans cho phép mô hình tự sinh values để điều chỉnh quá trình học, đạt 100% accuracy trên task passkey retrieval (S-NIAH-1) với context length 16K. Về long-context understanding, Hope architecture duy trì độ chính xác ổn định khoảng 70-80% với context length lên đến 10M tokens trên BABILong benchmark, vượt trội so với các baseline khác.

Các thành phần cốt lõi của NL có tiềm năng lớn để giải quyết các thách thức trong FL. Delta Gradient Descent (DGD) với adaptive decay term phụ thuộc vào trạng thái của weights giúp mô hình xử lý tốt hơn các mối phụ thuộc trong quá trình local updates tuần tự tại mỗi client, từ đó làm giảm hiện tượng client drift gây ra bởi dữ liệu non-IID. Multi-scale Momentum Muon (M3) sử dụng nhiều momentum terms ở các timescales khác nhau, cho phép lưu giữ thông tin dài hạn về gradient landscape, giúp mô hình tránh rơi vào local minima và xử lý tốt hơn các conflicting gradients đến từ các clients khác nhau. Bên cạnh đó, Newton–Schulz orthogonalization trong M3 giúp giảm xung đột khi tổng hợp các cập nhật từ các non-IID clients, qua đó cải thiện tính ổn định của quá trình hội tụ.

Tuy nhiên, việc tích hợp NL vào FL đặt ra nhiều câu hỏi nghiên cứu quan trọng cần được trả lời

- DGD và M3 có thể cải thiện khả năng xử lý non-IID gradients trong FL như thế nào ?
- Nếu áp dụng DGD và M3 cho FL thì convergence rate cũng như communication efficiency của chúng ra sao ?
- Làm sao cân bằng trade-off giữa local personalization và global performance trong FL-NL framework ?

Nghiên cứu này được thực hiện với mục tiêu trả lời các câu hỏi trên và phát triển các optimizer phân tán hiệu quả cho Federated Learning dựa trên các kỹ thuật trong Nested Learning.

1.2 Mục tiêu nghiên cứu

1.2.1. Mục tiêu tổng quát

Phát triển Federated Delta Gradient Descent (Fed-DGD) và Federated Multi-scale Momentum Muon (Fed-M3) từ Nested Learning framework để cải thiện hiệu quả huấn luyện trên dữ liệu non-IID trong Federated Learning.

1.2.2. Mục tiêu cụ thể

Mục tiêu 1: Phát triển Federated Delta Gradient Descent (Fed-DGD):

- Nghiên cứu và điều chỉnh Delta Gradient Descent từ Nested Learning sang môi trường federated learning. Thiết kế cơ chế cập nhật tại client với adaptive decay term phụ thuộc vào trạng thái weights và dữ liệu hiện tại để xử lý tương quan trong dữ liệu non-IID.
- Phát triển cơ chế tổng hợp tại server phù hợp với đặc thù của adaptive decay, bao gồm hai phương án: tổng hợp cả thông tin weights và decay, hoặc chỉ tổng hợp weights cuối cùng.

Mục tiêu 2: Phát triển Federated Multi-scale Momentum Muon (Fed-M3):

- Nghiên cứu và điều chỉnh Multi-scale Momentum Muon từ Nested Learning sang môi trường federated learning. Thiết kế cấu trúc momentum đa cấp với fast momentum tại clients và slow momentum tại server để lưu giữ thông tin dài hạn về gradient landscape.
- Tích hợp Newton-Schulz orthogonalization vào quá trình tổng hợp để giảm xung đột giữa các gradients từ clients khác nhau.

Mục tiêu 3: Đánh giá trên các Benchmark Non-IID:

- Tiến hành thí nghiệm trên bộ dữ liệu FMNIST với mô hình CNN đơn giản và CIFAR-10 với ResNet-18. Mô phỏng được thiết lập với số client khác nhau.
- Phương pháp đề xuất được so sánh với các baseline phổ biến trong federated learning, bao gồm FedAvg, FedProx, SCAFFOLD, FedAdam, cũng như mô hình huấn luyện tập trung (centralized) Muon. Hiệu năng được đánh giá dựa trên các tiêu chí: độ chính xác, tốc độ hội tụ, chi phí giao tiếp và độ ổn định trong quá trình huấn luyện.

1.3. Tính mới và những đóng góp của đề tài

Về mặt lý thuyết, đây là đề tài đầu tiên điều chỉnh Delta Gradient Descent với adaptive decay term từ centralized setting sang federated setting với nhiều clients có phân bố dữ liệu khác nhau. Đây cũng là nghiên cứu đầu tiên mở rộng Multi-scale Momentum Muon cho distributed optimization, thiết kế cấu trúc momentum đa cấp phù hợp với kiến trúc client-server của FL. Đề tài đề xuất sử dụng Newton-Schulz orthogonalization để xử lý các gradients xung đột trong quá trình tổng hợp federated, một ứng dụng mới trong bối cảnh non-IID FL.

Về mặt kỹ thuật, đề tài phát triển cơ chế tổng hợp adaptive decay cho Fed-DGD để kết hợp thông tin decay từ các clients không đồng nhất. Thiết kế cấu trúc momentum phân cấp trong Fed-M3 với sự phân tách rõ ràng giữa việc theo dõi động lượng cục bộ và động lượng toàn cục. Tích hợp orthogonalization vào quá trình tổng hợp federated một cách hiệu quả, cân bằng giữa chi phí tính toán và cải thiện hội tụ.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm Delta Gradient Descent (DGD) từ Nested Learning framework với adaptive decay mechanism phụ thuộc vào trạng thái weights và dữ liệu hiện tại. Multi-scale Momentum Muon (M3) với fast momentum cho theo dõi ngắn hạn, slow momentum cho ổn định dài hạn, và Newton-Schulz orthogonalization. Federated Learning với kiến trúc client-server trong cross-device setting, các cơ chế tổng hợp để kết hợp updates từ nhiều clients, và communication protocols. Các thuật toán tối ưu hóa cho môi trường phân tán bao gồm gradient-based optimizers, momentum-based methods, và adaptive learning rates.

1.4.2 Phạm vi nghiên cứu

Về không gian: Thử nghiệm trên nhiều kịch bản có số lượng client khác nhau (5-100 client).

Về thời gian: 3-6 tháng thực hiện, chia thành giai đoạn thiết kế (tháng 1-2), thử nghiệm và đánh giá (tháng 2-4), viết luận văn(tháng 4-6).

Về dữ liệu: Sử dụng hai bộ dữ liệu là FMNIST (70K images, 10 classes, 28×28 grayscale) và CIFAR-10 (60K images, 10 classes, 32×32 RGB).

Về mô hình: Simple CNN (~1M parameters) cho FMNIST và ResNet-18 (~11M parameters) cho CIFAR-10. Model size từ 1-100M parameters.

Không thuộc phạm vi: Tính riêng tư (privacy), khả năng chống tấn công Byzantine, công bằng giữa các clients, và tối ưu hóa cho phần cứng cụ thể.

2. Nội dung của đề tài, các vấn đề cần giải quyết

Luận văn đề xuất một tiếp cận mới cho vấn đề tối ưu hóa trong Federated Learning với dữ liệu không đồng nhất (non-IID), đó là "Áp dụng các kỹ thuật Nested Learning cho Federated Learning". Các nội dung chính của đề tài này gồm có:

- **Tìm hiểu tổng quan về Federated Learning và thách thức từ dữ liệu non-IID.**
    - Nghiên cứu kiến trúc FL cơ bản, thuật toán FedAvg
    - Phân tích các dạng non-IID: feature skew, label skew, quantity skew
    - Khảo sát các phương pháp hiện tại: FedProx, SCAFFOLD, FedDyn, FedOpt, SlowMo và các hạn chế còn tồn tại
- **Nghiên cứu paradigm Nested Learning và các kỹ thuật tối ưu đa cấp.**
    - Nghiên cứu Delta Gradient Descent (DGD) với adaptive decay term
    - Nghiên cứu Multi-scale Momentum Muon (M3) với cấu trúc động lượng phân cấp và Newton-Schulz orthogonalization
- **Xây dựng Federated Delta Gradient Descent (Fed-DGD).**
    - Thiết kế cơ chế cập nhật cục bộ tích hợp adaptive decay
    - Đề xuất hai chiến lược aggregation tại server (tường minh và ngầm)
    - Thực hiện ablation study đánh giá đóng góp của từng thành phần
- **Xây dựng Federated Multi-scale Momentum Muon (Fed-M3).**
    - Thiết kế cấu trúc động lượng phân cấp: fast momentum ở client, slow momentum ở server
    - Tích hợp Newton-Schulz orthogonalization để giảm xung đột gradient
    - Khảo sát các hyperparameters và thực hiện ablation study có hệ thống
- **Đánh giá toàn diện trên các benchmark non-IID.**
    - So sánh Fed-DGD và Fed-M3 với 6 baselines: FedAvg, FedProx, SCAFFOLD, FedAdam, FedYogi, Muon centralized
    - Thực nghiệm trên FMNIST và CIFAR-10
    - Đo lường test accuracy, personalized accuracy, tốc độ hội tụ và chi phí giao tiếp
- **Phân tích các kết quả về tính hiệu quả, độ ổn định và khả năng thích ứng.**

- Chứng minh hiệu quả của adaptive decay và multi-scale momentum trong môi trường non-IID
- Phân tích vai trò của orthogonalization trong việc giảm xung đột gradient
- So sánh trade-off giữa hiệu suất và chi phí truyền thông

Cách tiếp cận này có thể được áp dụng rộng rãi trong các ứng dụng Federated Learning thực tế như: học máy trên thiết bị di động (mobile devices), hệ thống y tế phân tán với dữ liệu bệnh nhân được bảo mật, dự báo và phân tích dữ liệu tài chính từ nhiều tổ chức, hệ thống IoT với dữ liệu cảm biến phân tán. Nó cũng được áp dụng cho các kịch bản continual learning và personalization trong các hệ thống khuyến nghị, trợ lý ảo và các ứng dụng AI edge computing.

- Cấu trúc dự kiến báo cáo kết quả của đề tài:

Lời mở đầu.

Chương 1. Cơ sở lý thuyết

1.1. Phát biểu bài toán
1.2. Federated Learning cơ bản
1.3. **Nested Learning**
1.4. Các kỹ thuật tối ưu hóa

Chương 2. Các phương pháp liên quan trong học phân tán lồng nhau

2.1. Phương pháp Regularization-based
2.2. Phương pháp Personalization-based
2.3. Phương pháp Adaptive Optimization

Chương 3. Một số mô hình học máy phân tán đề xuất

3.1 Phân tích khoảng trống nghiên cứu

3.2. Federated Delta Gradient Descent (Fed-DGD) -> Xây dựng mô hình phân tán sử dụng Fed-DGD

- Cơ sở lý thuyết
- Thuật toán
- Mô hình

3.3. Federated Multi-scale Momentum Muon (Fed-M3) -> Xây dựng mô hình phân tán sử dụng Fed-M3

- Cơ sở lý thuyết
- Thuật toán
- Mô hình

Chương 4. Thực nghiệm và đánh giá

4.1. Dữ liệu và thiết lập thực nghiệm
4.2. Kết quả Fed-DGD

4.3. Kết quả Fed-M3
4.4. So sánh và phân tích
4.5. Thảo luận

Kết luận và hướng phát triển.

Tài liệu tham khảo.

4. Dự kiến tiến độ nghiên cứu

TT	Hoạt động nghiên cứu	Thời gian thực hiện		Sản phẩm khoa học
		Từ tháng	Đến tháng	
1.	Tìm hiểu tổng quan về Federated Learning, dữ liệu non-IID và các phương pháp hiện tại (FedAvg, FedProx, SCAFFOLD)	01/2026	02/2026	Báo cáo tổng quan về Federated Learning, phân tích các dạng non-IID (feature skew, label skew, quantity skew) và khảo sát các phương pháp hiện tại
2.	Nghiên cứu Nested Learning framework, Delta Gradient Descent và Multi-scale Momentum Muon	02/2026	03/2026	Báo cáo phân tích Delta Gradient Descent (DGD) với adaptive decay term và Multi-scale Momentum Muon (M3) với cấu trúc momentum phân cấp và Newton-Schulz orthogonalization.

TT	Hoạt động nghiên cứu	Thời gian thực hiện		Sản phẩm khoa học
		Từ tháng	Đến tháng	
3.	Xây dựng Federated Delta Gradient Descent (Fed-DGD) và Federated Multi-scale Momentum Muon (Fed-M3)	03/2026	04/2026	Tài liệu thiết kế thuật toán Fed-DGD và Fed-M3, bao gồm công thức toán học, pseudo-code, phân tích lý thuyết hội tụ và communication complexity.
4.	Triển khai phương pháp đề xuất và thiết lập môi trường thực nghiệm	03/2026	04/2026	Source code Python cho Fed-DGD và Fed-M3, môi trường thực nghiệm trên FMNIST và CIFAR-10 với các kịch bản non-IID, tài liệu kỹ thuật hướng dẫn cài đặt và cấu hình.
5.	Thực hiện thực nghiệm, đo lường hiệu năng và ablation studies	04/2026	04/2026	Kết quả đo lường test accuracy, personalized accuracy, tốc độ hội tụ, chi phí giao tiếp và ablation studies đánh giá đóng góp của từng thành phần.

TT	Hoạt động nghiên cứu	Thời gian thực hiện		Sản phẩm khoa học
		Từ tháng	Đến tháng	
6.	So sánh với baselines và phân tích kết quả	05/2026	05/2026	Bản luận văn thạc sĩ hoàn thiện với đầy đủ cơ sở lý thuyết, phương pháp đề xuất (Fed-DGD và Fed-M3), kết quả thực nghiệm và phân tích chi tiết.
7.	Viết báo cáo tổng hợp và hoàn thiện luận văn	05/2026	05/2026	Bản luận văn hoàn thiện
8.	Chuẩn bị slides, bảo vệ luận văn	06/2026	06/2026	

5. Cán bộ hướng dẫn

Họ và tên: Trần Trọng Hiếu

Chức danh khoa học: Tiến Sĩ

Cơ quan công tác: Trường Đại học Khoa học Tự nhiên, ĐHQG Hà Nội

Điện thoại: 0945893663 Email: tranthieu2005@gmail.com

- Ý kiến nhận xét, đánh giá của cán bộ hướng dẫn:
  (*ký và ghi rõ họ, tên*)

- Xác nhận của Bộ môn:

Hà Nội, ngày tháng năm 20

Học viên

(*ký và ghi rõ họ tên*)

Tài liệu tham khảo

Federated Learning - Nền tảng

[1] McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 54, 1273-1282.

[2] Smith, V., Chiang, C. K., Sanjabi, M., & Talwalkar, A. S. (2017). Federated multi-task learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.

[3] Kairouz, P., McMahan, H. B., Avent, B., Bellet, A., Bennis, M., Bhagoji, A. N., ... & Zhao, S. (2021). Advances and open problems in federated learning. *Foundations and Trends in Machine Learning*, 14(1-2), 1-210.

Non-IID Data và Client Drift

[4] Zhao, Y., Li, M., Lai, L., Suda, N., Civin, D., & Chandra, V. (2018). Federated learning with non-IID data. *arXiv preprint arXiv:1806.00582*.

[5] Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems (MLSys)*, 2, 429-450.

[6] Karimireddy, S. P., Kale, S., Mohri, M., Reddi, S., Stich, S., & Suresh, A. T. (2020). SCAFFOLD: Stochastic controlled averaging for federated learning. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 119, 5132-5143.

Phương pháp FL hiện tại

[7] Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). FedProx: Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems (MLSys)*, 2, 429-450.

[8] Acar, D. A. E., Zhao, Y., Navarro, R. M., Mattina, M., Whatmough, P. N., & Saligrama, V. (2021). Federated learning based on dynamic regularization. *International Conference on Learning Representations (ICLR)*.

[9] Reddi, S., Charles, Z., Zaheer, M., Garrett, Z., Rush, K., Konečný, J., ... & McMahan, H. B. (2021). Adaptive federated optimization. *International Conference on Learning Representations (ICLR)*.

[10] Wang, J., Liu, Q., Liang, H., Joshi, G., & Poor, H. V. (2020). Tackling the objective inconsistency problem in heterogeneous federated optimization. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 7611-7623.

Personalization trong FL

[11] Fallah, A., Mokhtari, A., & Ozdaglar, A. (2020). Personalized federated learning with theoretical guarantees: A model-agnostic meta-learning approach. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 3557-3568.

[12] Li, T., Hu, S., Beirami, A., & Smith, V. (2021). Ditto: Fair and robust federated learning through personalization. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 139, 6357-6368.

[13] Arivazhagan, M. G., Aggarwal, V., Singh, A. K., & Choudhary, S. (2019). Federated learning with personalization layers. *arXiv preprint arXiv:1912.00818*.

Nested Learning

[14] Behrouz, A., Razaviyayn, M., Zhong, P., & Mirrokni, V. (2025). Nested Learning: The Illusion of Deep Learning Architectures. Advances in Neural Information Processing Systems (NeurIPS), 38.

Optimization Methods

[15] Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*.

[16 Zaheer, M., Reddi, S., Sachan, D., Kale, S., & Kumar, S. (2018). Adaptive methods for nonconvex optimization. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[17] Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*.

Datasets

[18] Krizhevsky, A., & Hinton, G. (2009). Learning multiple layers of features from tiny images. *Technical Report*, University of Toronto.

[19] Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*.

[20] Larson, S., Mahendran, A., Peper, J. J., Clarke, C., Lee, A., Hill, P., ... & Mars, J. (2019). An evaluation dataset for intent classification and out-of-scope prediction. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 1311-1316.